

Anexo I

PROBLEMAS DE CALIDAD DE DATOS EN BASES DE DATOS RELACIONALES

Según Oliveira et al. (2005), los problemas de calidad de datos en bases de datos relacionales se pueden tratar cuatro niveles de granularidad: varias fuentes de datos, varias relaciones (tablas), una simple relación, y nivel de atributo/tupla. En esta clasificación de problemas, los autores no incluyen datos multimedia.

A1.1 PROBLEMAS A NIVEL DE ATRIBUTO / TUPLAS

Este tipo de problemas se pueden dar en los siguientes elementos: i) un atributo de una tupla; ii) un atributo en muchas tuplas (a nivel de columna); o iii) varios atributos a nivel de una tupla (a nivel de fila).

A1.1.1 Un atributo en una tupla

- Valores perdidos, por ejemplo, cuando falta un valor en un atributo en cuya definición se estableció como no nulo. Este tipo de problema tiene que ver con la dimensión de la completitud.
- Violación de sintaxis, cuando por ejemplo se establece una expresión regular para el formato de un atributo de correo electrónico de la forma *usuario@subdominio.dominio* y se almacena “*ismael@uclm*”. Este tipo de problema tiene que ver con la dimensión de la precisión sintáctica.

- Valores incorrectos, por ejemplo, cuando en una base de datos se tiene el atributo nombre autor, y se sabe que es “*Mario Piattini*”, aparece “*Mariano Piattini*”. Este tipo de problema tiene que ver con la dimensión de la precisión semántica.
- Violación de dominio, por ejemplo, cuando para el atributo *NúmeroOrden* aparece el valor -5 (en una secuencia de orden, no deben aparecer valores negativos).
- Violación de las restricciones, por ejemplo, cuando se establecen que para poder registrarse en una web hace falta ser mayor de edad y no se verifica que (*EdadActual* ≥ 18).
- Subcadena con contenido inválido para el tipo de dato, se correspondería con un tipo de violación de dominio, por ejemplo, cuando al almacenar el código postal, se almacenará también el nombre de la localidad.
- *Error de Deletreo*, es un tipo de error específico que se correspondería con una violación de sintaxis cuando hay una variación de una letra en el valor del atributo. Por ejemplo, cuando se almacena “*Ismeal*” por “*Ismael*”.
- Valores imprecisos, es un tipo de error específico cuando no es posible interpretar un valor sustitutivo que se da. Por ejemplo, cuando se especifica “ISO”, y no se sabe si se corresponde con “*International Organization for Standardization*” o con “*Inspection of Supplies*”.

A1.1.2 Atributos en varias tuplas (alcance de columna)

- Violación de valor único. Ocurre cuando por ejemplo dos personas diferentes se almacenan teniendo el mismo DNI.
- Existencia de sinónimos. Este problema aparece cuando aparecen como valores del atributo palabras que son consideradas como sinónimas. Por ejemplo, cuando para el atributo Profesión en una tupla aparece “Profesor” y en otras aparece “Maestro”.
- Violación de restricciones, que afecten a varias tuplas.

A1.1.3 Varios atributos en una tupla

- **Tupla semivacía.** Ocurre cuando no todos los atributos de una tupla tienen valores. Para considerar que una tupla puede seguir siendo válida se puede identificar un valor umbral del número de atributos que no deben ser nulos (e.g. 60%), o incluso, en función de la importancia de los atributos, dar un peso específico a cada uno de los atributos a la hora de computar la validez de la tupla con respecto al valor umbral.
- **Violación de dependencia funcional.** Supóngase una tabla que contenga los atributos, *CódigoPostal* y *Ciudad*, de los que se sabe que *CódigoPostal* determina *Ciudad*. Se produce una violación de dependencia funcional cuando en la tabla aparecen para una tupla *CódigoPostal*=13071 y *Ciudad*= “Ciudad Real” y *CódigoPostal*=13071 y *Ciudad*= “Madrid”.
- **Violación de restricciones de dominio.** Este tipo de violación puede ocurrir cuando se define el valor de un atributo en función de otro(s) dentro de la misma tupla según las restricciones del dominio, pero luego el valor que se inserta no está calculado según esas reglas. Por ejemplo, cuando en una relación (*NumeroUnidades*, *PrecioUnitario*, *TotalPrecio*) existe una cantidad que se llama *TotalPrecio* que se calcula como *NúmeroUnidades* * *PrecioUnitario* y a la hora de insertar una tupla se inserta como (4, 30, 150).

A1.2 PROBLEMAS A NIVEL DE RELACIÓN

- **Tuplas aproximadamente duplicadas.** Este problema surge cuando dos o más tuplas tienen valores correspondientes a la misma entidad de la realidad, aunque estos valores no son exactamente iguales. Por ejemplo, cuando aparecen para una relación *Cliente* (*CodPersona*, *Nombre*, *Ciudad*) dos tuplas (1223, “Francisco Sánchez”, “Ciudad Real”) y (8553, “Fco. Sánchez”, “Cdad. Real”). Para resolver este tipo de problema se usan las técnicas de resolución de entidad (*Talbert 2011*).
- **Tuplas inconsistentemente duplicadas.** Este tipo de problema es similar al anterior, pero con la diferencia de que, en este caso, las claves primarias son exactamente iguales. Siguiendo el ejemplo anterior, y

suponiendo que el primer atributo es la clave primaria, un ejemplo de Tuplas inconsistentemente duplicadas sería (1223, “Francisco Sánchez”, “Ciudad Real”) y (1223, “Fco. Sánchez”, “Ciudad Real”).

- **Violación de restricciones de dominio.** Un ejemplo de situación de este tipo de problema es cuando por una cierta regla de negocio, sólo se permite a un cliente adquirir 10 productos, y en la tabla de *ClienteCompraProducto* aparece que ha comprado ese producto más de 10 veces.

Muchos de los problemas anteriores se pueden afrontar haciendo un diseño más comprensivo o completo del esquema de la base de datos, y además debe ocurrir que el Sistema Gestor de Bases de Datos (SGBD) lo soporte.

A1.3 PROBLEMAS A NIVEL DE VARIAS RELACIONES

- **Violaciones de integridad referencial.** Este es uno de los problemas más típicos en bases de datos relacionales en las que no se definen bien las claves ajenas. Un ejemplo de manifestación de este tipo de problema es cuando se tiene en una tabla una clave ajena cuyo valor no está en la clave primaria a la que referencia. Por ejemplo, cuando se tienen las relaciones *Domicilio* (*CodPersona*, *Calle*, *CP*) y *Poblacion* (*CP*, *NombrePoblación*) con *Domicilio.CP* → *Población*, y se tiene una tupla *Domicilio* (“Ismael”, “c\ Paz”, 13005), pero en la tabla *Población* no aparece ninguna tupla con CP=13005.
- **Referencias incorrectas.** En el ejemplo anterior, este tipo de problema aparece cuando, existiendo un posible valor para el CP, éste no se corresponde con el que se pretende almacenar. Por ejemplo, cuando la tupla anterior *Domicilio* (“Ismael”, “c\ Paz”, 18025), el valor en realidad para el código postal debería ser 13005.
- **Heterogeneidad de sintaxis.** Este tipo de problema se produce por ejemplo cuando el formato del mismo dato en tuplas diferentes tiene diferentes formatos. Por ejemplo, cuando en la relación *Vuelo* (*CodVuelo*, *Origen*, *Destino*, *HoraSalida*, *HoraLlegada*) la hora de salida se expresa como “22:00 CET”, mientras que en la relación *Facturacion* (*CodCliente*, *CodVuelo*, *HoraSalida*), la hora de salida

se muestra como “10:00 PM CET”: son la misma hora, pero como se expresan de forma diferente, puede originar errores en una posible computación.

- **Bucles entre tuplas auto-referenciadas.** Este tipo de problema se suele dar en relaciones que dependen de otras que contienen a su vez referencias a la primera. Por ejemplo, supóngase que se tiene una relación *Producto* (*CodProducto*, *CodSubproducto*), donde *CodSubproducto* hace referencia a un producto que forma parte de otro producto. Puede aparecer este tipo de problemas si dentro de la base de datos existieran dos tuplas *Producto* (“X”, “Y”) y *Producto* (“Y”, “X”), es decir, que un producto “X” tiene como subproducto a otro “Y” del que al mismo tiempo es el producto cuyo subproducto es “X”.
- **Violaciones de restricciones de dominio.** Siguiendo con el ejemplo de las facturas, este tipo de problema se da cuando el atributo *FacturaciónTotal* de una relación *Facturas* (*CodCliente*, *CodFactura*, *FacturaciónTotal*) tiene el valor 1000€, pero la suma de todas las ventas de la relación *Ventas* (*CodCliente*, *CodFactura*, *CodProducto*, *Unidades*, *Precio*) que se facturan en una misma factura tiene un valor calculado de 1200€.

A1.4 PROBLEMAS A NIVEL DE MÚLTIPLES FUENTES

Para presentar este tipo de problemas, asumimos que se tienen dos relaciones que pertenecen a dos fuentes de datos diferentes. Ambas relaciones representan la misma entidad del mundo real, y supongamos, que, por simplicidad, se han resuelto algunos asuntos como heterogeneidad de nombres, aunque el número de atributos en cada una de ella puede variar, incluso, a nivel de granularidad para mantener los mismos conceptos. En estas circunstancias (*Oliveira, Rodrigues et al. 2005*) identifican los siguientes problemas:

- **Heterogeneidad de sintaxis.** Este problema ocurre cuando la sintaxis de un atributo de una relación de una fuente de dato es diferente a la del mismo atributo de otra fuente de datos. En el ejemplo de los vuelos, una aerolínea puede almacenar que la hora de salida de un vuelo son las “10:00 PM CET”, mientras que, para la gestora del aeropuerto, la

hora de salida de ese mismo vuelo pueden ser las “22:00 CET”. El valor del dato es el mismo, pero está expresado con diferente sintaxis.

- **Heterogeneidad de unidades de medida.** Siguiendo el mismo ejemplo de los vuelos, se produce un problema de este tipo, cuando el precio del vuelo se expresa para una aerolínea en euros, y para una agencia de viaje en dólares.
- **Heterogeneidad de presentación.** Este tipo de problema ocurre cuando en ambas fuentes de datos se eligen representaciones diferentes para el valor de un determinado atributo. Por ejemplo, cuando para el género, en una fuente de datos se elige (“H”, “M”) y en la otra (0, 1).
- **Existencia de sinónimos.** Se suele dar este tipo de problema cuando una de las fuentes de datos elige nombres diferentes para el mismo concepto, bien por temas culturales, bien por temas de nomenclatura. Por ejemplo, cuando en una relación de personal, el atributo *CategoríaProfesional* para una aerolínea española contiene el valor de “azafata”, mientras que para una mexicana contiene el valor “aeromoza”.
- **Tuplas aproximadamente duplicadas.** Al igual que lo que sucedía para el caso de una única tupla (véase subapartado anterior), puede ocurrir que para una fuente de datos se tenga unos valores, mientras que para la otra fuente se tengan otros similares, pero no exactamente los mismos. Por ejemplo, para el caso de un trabajador en la compañía aérea Iberia se tenga en la relación *Trabajador(CodTrabajador, Nombre, FechaIncorporación)* una tupla (“A001”, “Francisco Ruiz”, “20/02/1990”) y para la asesoría que gestiona las nóminas de los trabajadores, se tiene una relación *Trabajador(CodTrabajador, Nombre, FechaIncorporación)* una tupla (“Iberia-A001”, “Francisco Ruiz”, “20/02/1990”). Obviamente se refieren al mismo trabajador, pero internamente cada organización lo identifica de forma diferente.
- **Tuplas inconsistentemente duplicadas.** Sería una situación especial del caso anterior donde algunos de los atributos no están adecuadamente replicados. Por ejemplo para el caso anterior del trabajador de la compañía aérea Iberia se tiene en la relación *Trabajador(CodTrabajador, Nombre, FechaIncorporación)* una tupla (“A001”, “Francisco Ruiz”, “20/02/1990”) y para la asesoría que gestiona

las nóminas de los trabajadores, se tiene una relación *Trabajador* (*CodEmpresa*, *CodTrabajador*, *Nombre*, *FechaIncorporación*) una tupla (“Iberia”, “X230989”, “Francisco Ruiz”, “20/02/1990”).

- **Violaciones de restricciones de dominio.** Este tipo de problema puede aparecer cuando se han definido unas reglas de negocio que no coinciden en ambas fuentes de datos, pero hacen referencia al mismo hecho. Por ejemplo, cuando en la compañía la suma de todos los equipajes facturados no debe superar los 32 Kg., mientras que para el sistema de facturación del aeropuerto solo permite 23 Kg.